

Predição de Gasto Calórico em Atividades Físicas Utilizando Redes Neurais Artificiais Perceptron Multicamadas

1st João G. S. Lima

Bacharelado em Tecnologia da Informação
Universidade Federal Rural do Semi-Árido (UFERSA)
Pau dos Ferros, Brasil
joao.lima65418@alunos.ufersa.edu.br

2nd Rosana C. B. Rego

Departamento de Engenharias e Tecnologia
Universidade Federal Rural do Semi-Árido (UFERSA)
Pau dos Ferros, Brasil
rosana.rego@ufersa.edu.br

Resumo—A quantificação precisa do gasto calórico é fundamental para o planejamento nutricional e a otimização de treinos físicos personalizados. Este trabalho apresenta o desenvolvimento e a otimização empírica de uma Rede Neural Artificial Perceptron Multicamadas (MLP) voltada para a predição contínua do dispêndio energético. A partir de uma base de dados contendo 15.000 amostras de perfis biométricos, exploraram-se sistematicamente diferentes configurações arquiteturais. O modelo ótimo alcançado composto por uma única camada oculta de 128 neurônios treinada durante 100 épocas demonstrou capacidade preditiva e robustez contra sobreajuste, registrando um Erro Médio Absoluto (MAE) de apenas 0,34 kcal e um Coeficiente de Determinação (R^2) de 1,0000 no conjunto de teste. Incorporou-se a metodologia de Inteligência Artificial Explicável (XAI) baseada em valores SHAP para entender o impacto de cada variável na predição. A análise de explicabilidade validou a coerência biológica da rede, apontando a duração do exercício e a frequência cardíaca como os atributos primários na modulação calórica. Os resultados comprovam a eficácia da abordagem proposta, estabelecendo um modelo de alta precisão preditiva, viabilizando estimativas energéticas sem a necessidade de modelos estruturalmente complexos.

Palavras chaves—Redes neurais artificiais, perceptron multicamadas, predição calórica, regressão.

I. INTRODUÇÃO

O cuidado com a saúde física e com o peso corporal tornaram-se prioridades crescentes nas sociedades contemporâneas. Estimativas globais indicam que aproximadamente 64% da população adulta engaja-se em atividade física regularmente [1]. Neste contexto, a quantificação precisa do gasto energético durante o exercício surge como informação crucial para otimização de treinos e elaboração de planos nutricionais personalizados.

As Redes Neurais Artificiais (RNAs) oferecem uma alternativa promissora. Especificamente, o Perceptron Multicamadas (*MultiLayer Perceptron* – MLP) é uma arquitetura que combina: (i) capacidade de aproximar funções não lineares arbitrariamente complexas [2], (ii) treinamento eficiente via retropropagação [3], e (iii) aplicabilidade demonstrada em problemas de regressão biométrica [4].

Nesse contexto surge a seguinte pergunta: *Pode um modelo de Rede Neural Artificial Perceptron Multicamadas, treinado*

em dados de características fisiológicas, produzir previsões de gasto calórico suficientemente precisas e interpretáveis para aplicação prática em contextos de treinamento personalizado?

A. Objetivos

Este trabalho tem os seguintes objetivos:

- 1) Desenvolver uma rede neural MLP otimizada para predição de gasto calórico, explorando diferentes arquiteturas por meio de busca empírica de hiperparâmetros;
- 2) Avaliar a capacidade preditiva do modelo por meio de métricas quantitativas, estabelecendo comparativos entre as redes;
- 3) Explicar quais variáveis fisiológicas e de atividade física influenciam as previsões.

II. FUNDAMENTAÇÃO TEÓRICA

A. Redes Neurais Artificiais

As RNAs são modelos computacionais inspirados na estrutura e funcionamento do cérebro biológico, compostos por unidades de processamento interconectadas denominadas neurônios artificiais [5]. Cada neurônio recebe múltiplas entradas ponderadas, realiza uma transformação não linear e transmite a saída para os neurônios subsequentes.

A base matemática de um neurônio artificial é expressa por:

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right) \quad (1)$$

em que x_i representa as entradas, w_i são os pesos sinápticos, b é o viés (bias) e $f(\cdot)$ é a função de ativação não linear. A capacidade de aprendizado das redes neurais reside na adaptação iterativa dos parâmetros w_i e b durante o processo de treinamento, permitindo capturar relações complexas entre variáveis.

B. Perceptron Multicamadas

O MLP é uma arquitetura de rede neural feedforward composta por múltiplas camadas de neurônios interconectados organizados hierarquicamente [4]. A estrutura típica de uma MLP compreende três tipos de camadas:

- 1) Camada de Entrada: Recebe os dados brutos do problema;
- 2) Camadas Ocultas: Realizam transformações não lineares sucessivas dos dados, possibilitando a extração de características abstratas e a modelagem de relações complexas;
- 3) Camada de Saída: Produz o resultado final, cuja dimensionalidade é determinada pela tarefa.

C. Regressão com Redes Neurais

Problemas de regressão envolvem a predição de variáveis contínuas a partir de variáveis preditoras [6]. Uma MLP pode ser configurada para regressão através de:

- 1) Um neurônio de saída com ativação linear;
- 2) Uma função de perda contínua, tipicamente o Erro Quadrático Médio (MSE).

A função de perda MSE é definida como:

$$L_{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2)$$

em que n é o número de amostras, y_i são os valores verdadeiros e $\hat{y}_i$ são as predições da rede. O MSE penaliza erros grandes de forma quadrática, sendo sensível a *outliers*, razão pela qual métricas complementares como o o Erro Médio Absoluto (*Mean Absolute Error* - MAE) são frequentemente consideradas [4].

D. Inteligência Artificial Explicável

Modelos de RNAs, embora poderosos, são frequentemente considerados caixas-pretas, dificultando a interpretação das decisões. A metodologia SHAP (*SHapley Additive exPlanations*) fundamenta-se na teoria dos valores de Shapley da teoria dos jogos cooperativos para atribuir importância a cada característica [7]. O valor de Shapley para uma característica j é:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(m - |S| - 1)!}{m!} [f(S \cup \{j\}) - f(S)] \quad (3)$$

em que F é o conjunto completo de características, $m = |F|$ e $f(S)$ é a predição do modelo utilizando apenas o subconjunto S de características. SHAP quantifica a contribuição marginal de cada feature na predição final, permitindo interpretação local e global do comportamento da rede [7].

III. METODOLOGIA

Esse Estudo adotou uma metodologia experimental de caráter exploratório. Tendo em vista a ausência de métodos determinísticos para a definição de uma topologia inicial para redes neurais, foi feito o uso de uma abordagem empírica, baseada na variação iterativa dos valores dos hiperparâmetros. A eficácia das configurações testadas foram avaliada pelas métricas objetivas para problemas de regressão, além da análise do gráfico de perda, a fim de observar o aprendizado da rede para evitar *overfitting* ou *underfitting*.

A. Conjunto de dados

Foi utilizado o *dataset fmenes-DAT263x-demos* obtido via Kaggle. O conjunto é composto por 15.000 amostras, as variáveis de predição são *Gender*, *Age*, *Height*, *Weight*, *Duration*, *Heart_Rate* e *Body_Temp* além da variável alvo *Calories*.

B. Pré-processamento dos Dados

O *dataset* é dividido em dois arquivos CSV, o primeiro *exercise*, que contém as variáveis para predição, e o segundo *calories* com os valores de calorias gastos. Realizou-se a junção entre as tabelas, por meio da chave *User_ID* para garantir que as métricas físicas correspondam de forma exata à caloria gasta pela mesma pessoa. A técnica de *One-Hot Encoding* é utilizada na variável do tipo texto *Gender*, transformando para representação binária, com um representando o sexo masculino como 1 e o feminino como 0.

A coluna de identificação *User_ID* foi descartada por não carregar valor preditivo. A variável contínua *Calories* foi isolada como o valor alvo da regressão, enquanto as variáveis físicas e de atividade compuseram o conjunto de atributos preditores. A base de dados foi particionada em proporções de 80% para treinamento e 20% para teste. Subsequentemente, realizou-se a padronização das variáveis preditoras por meio do *escore* padronizado via *StandardScaler*. A fim de mitigar o risco de vazamento de dados, os parâmetros estatísticos foram calculados exclusivamente no conjunto de treino mediante a aplicação do método *fit_transform*, aplicando-se apenas a operação de projeção (*transform*) sobre os dados de teste.

C. Arquitetura da Rede Neural

A busca arquitetural explorou diferentes quantidades de neurônios baseadas em potências de base dois, até o máximo de neurônios indicado pela equação:

$$N_h = \frac{N_s}{\alpha \cdot (N_{in} + N_{out})} \quad (4)$$

em que N_s representa o número de amostras no conjunto de treinamento, N_{in} corresponde à dimensão de entrada, N_{out} indica a dimensão de saída e α consiste em um fator de escala arbitrário entre 2 e 10. Adotando-se $\alpha = 5$, obteve-se um teto teórico de 300 neurônios para a partição de treino. A configuração final que apresentou os índices de generalização e menor erro preditivo é estruturada da seguinte forma:




Fig. 1. Representação da rede neural.

- Camada de Entrada: Composta por 7 neurônios, correspondendo às variáveis preditoras;
- Camada Oculta: Uma única camada composta por 128 neurônios com função de ativação ReLu (*Rectified Linear Unit*);
- Camada de Saída: Composta por um único neurônio com ativação linear ($\hat{y} = \mathbf{w}^T \mathbf{x} + b$), dimensionada para fornecer a predição contínua do gasto calórico total.

A comparação sistemática de desempenho entre esta arquitetura e as demais topologias intermediárias testadas é apresentada e discutida na Seção IV.

D. Ambiente Computacional e Treinamento

O ambiente computacional para execução do treinamento foi o Google Colab, que disponibiliza uma CPU Intel(R) Xeon(R) CPU @ 2.00GHz e a GPU Tesla T4. A linguagem de programação empregada foi o Python (versão 3). Para o pré-processamento dos dados e treinamento, empregaram-se as bibliotecas *TensorFlow/Keras* e *Scikit-Learn*, complementadas por *Pandas*, *NumPy*, *Matplotlib* e *shap*.

O treinamento da rede neural utilizou o otimizador Adam (*Adaptive Moment Estimation*) com taxa de aprendizado padrão, parametrizado para minimizar a função de perda. O processo foi executado ao longo de 100 épocas com tamanho de lote fixado em 32.

E. Métricas

A validação quantitativa da capacidade preditiva da rede proposta foi mensurada no conjunto de teste por meio de quatro métricas de regressão como: o MSE, MAE, a Raiz do Erro Quadrático Médio (*Root Mean Squared Error* – RMSE) e o Coeficiente de Determinação (R^2). As formulações matemáticas adotadas são definidas conforme as Equações (5)–(7):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (6)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (7)$$

onde n representa o total de observações da partição de teste, y_i denota o gasto calórico real, $\hat{y}_i$ expressa o valor estimado pela rede e $\bar{y}$ constitui a média amostral dos valores reais.

O algoritmo *KernelExplainer* foi aplicado para decompor as estimativas pontuais e ranquear globalmente a relevância marginal de cada atributo biométrico e de exercício na modulação do dispêndio calórico.

IV. RESULTADOS E DISCUSSÃO

A tabela I apresentam os resultados obtido pelas diferentes configurações avaliadas sobre a partição de teste.

TABLE I
COMPARAÇÃO DE DESEMPENHO ENTRE AS ARQUITETURAS AVALIADAS

Neurônios	Camadas	Épocas	MSE	RMSE	MAE	R^2
8	1	50	20.81	4.56	3.22	0.9948
8	1	100	5.01	2.24	1.73	0.9988
16	1	50	3.16	1.78	1.24	0.9992
16	1	100	1.14	1.07	0.79	0.9997
32	1	50	1.60	1.26	0.91	0.9996
32	1	100	0.76	0.87	0.65	0.9998
64	1	50	0.90	0.95	0.67	0.9998
64	1	100	0.35	0.59	0.45	0.9999
64-32	2	50	0.27	0.52	0.40	0.9999
64-32	2	100	0.28	0.53	0.42	0.9999
128	1	50	0.46	0.68	0.48	0.9999
128	1	100	0.19	0.44	0.34	1.0000
128-64	2	50	0.21	0.46	0.36	0.9999
128-64	2	100	0.23	0.48	0.38	0.9999
256	1	50	0.28	0.53	0.39	0.9999
256	1	100	0.22	0.47	0.37	0.9999

É possível notar que o aumento de 50 para 100 épocas nas redes de 8 a 128 neurônios com uma camada, causou uma redução nas métricas MSR, RMSE e MAE, em evidência na rede de 8 neurônios onde o MAE foi reduzido em aproximadamente 46.3%, de 3.22, caindo para 1.73, o MSE de 20.81, indo para 5.01 e o RMSE para 2.24. Dessa forma demonstrando que para a rede, 100 épocas é uma ótima quantidade de iterações nos dados para este problema.

Ao chegar em 256 neurônios tivemos uma piora nos resultados, não superando os resultados obtidos com 128 neurônios, foi então adicionada mais uma camada oculta, 128 neurônios na primeira e 64 na segunda camada, assim como outra rede com 64 e 32 neurônios. O aumento das épocas resultou na elevação dos resultados das redes com duas camadas, o MAE da rede 64-32 subiu de 0,40 para 0,42 kcal e o da rede 128-64 avançou de 0,36 para 0,38 kcal. Essa dinâmica sinaliza o início de uma perda de capacidade de generalização decorrente da saturação de parâmetros combinada a um número excessivo de ciclos.

Constata-se, portanto, que a transição para duas camadas ocultas ou a alocação excessiva de neurônios não se justifica frente aos resultados e ao custo computacional da rede de camada única com 128 neurônios, a qual consolidou o menor MSE = 0.19 indicando que os erros foram pequenos nas amostras, e MAE = 0,34kcal, avaliado junto ao RMSE = 0.44, com uma diferença de apenas um decimo, revela uma

boa distribuição dos erros da rede, com um comportamento estável, e ainda explicou integralmente a variância amostral com $R^2 = 1,0000$.

A convergência do modelo durante o treinamento é detalhada na Fig. 2, a qual expressa a trajetória da função de perda ao longo das 100 épocas.




Fig. 2. Gráfico curva de perda MSE

Destaca-se o paralelismo consistente entre a curva de treinamento e a curva de validação interna, a qual acompanha de forma fidedigna o decaimento do erro. As sutis oscilações observadas no erro de validação a partir da época 40 constituem flutuações estocásticas típicas do gradiente descendente baseado em mini-lotes, sem configurar divergência estrutural. A ausência de bifurcação ascendente no erro de validação comprova que não ocorreu sobreajuste, atestando uma generalização regularizada.

A. IA explicável

A figura 3 nos ajuda a compreender quais entradas estão sendo mais impactadas para a rede prever o gasto calórico, onde azul representa valores baixos da variável e vermelho valores altos, indicando o sentido e magnitude do impacto na predição.




Fig. 3. Impacto global das variáveis físicas no gasto calórico

A duração do exercício e frequência cardíaca ocupam as posições de maior impacto, com valores SHAP variando

aproximadamente de -125 a +50 kcal, indicando que estas características modulam fortemente o gasto calórico predito. Este resultado sugere que exercícios mais longos consomem mais energia, e frequência cardíaca elevada reflete intensidade de esforço, demonstrando que os dois exercem alto impacto na predição, enquanto a altura e temperatura corporal têm menos influência.

A variável de Sexo apresenta impacto reduzido comparado às variáveis anteriores, com valores SHAP concentrados próximo a zero. Quando codificada como 1, representa indivíduos do sexo masculino, em vermelho, contribui com aproximadamente +25 kcal adicionais ao valor predito, sugerindo que homens apresentam gasto calórico ligeiramente superior neste dataset.

V. CONCLUSÃO

Este estudo apresentou o desenvolvimento e a otimização empírica de uma Rede Neural Perceptron Multicamadas voltada para a predição precisa do gasto calórico em atividades físicas. Por meio da exploração sistemática de hiperparâmetros, demonstrou-se que a alocação excessiva de neurônios ou a transição para topologias profundas com múltiplas camadas não se justifica frente à dimensionalidade do problema investigado. A RNA MLP estabelecida com uma única camada oculta de 128 neurônios e treinada ao longo de 100 épocas, alcançou desempenho de excelência no conjunto de teste e demonstrou que para esse tipo de problema apenas uma camada com 128 neurônios é suficiente. O modelo registrou um MAE de apenas 0,34 kcal, RMSE = 0,44 e explicou integralmente a variância amostral $R^2 = 1,0000$, atestando convergência estável e generalização livre tanto de *overfitting* quanto de *underfitting*.

Adicionalmente, a incorporação de técnicas de inteligência artificial explicável através do método SHAP superou a opacidade inerente às redes neurais, fornecendo transparência analítica às predições. O mapeamento global de impacto do modelo desenvolvido, evidencia que as métricas dinâmicas de esforço como duração do exercício e a frequência cardíaca são os moduladores primários da queima calórica. Em contrapartida, variáveis antropométricas estáticas exibiram influência apenas secundária na formulação do resultado.

Para trabalhos futuros, sugere-se a validação cruzada desta arquitetura em bases de dados contendo séries temporais de monitoramento contínuo e a avaliação de diferentes modalidades esportivas. Recomenda-se expandir o escopo experimental por meio do treinamento e avaliação do modelo em conjuntos de dados que contemplem exercícios de treinamento de força e hipertrofia.

Por fim, é possível dizer que a rede MLP proposta foi capaz de produzir predições de gasto calórico suficientemente precisas e interpretáveis.

VI. DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Em conformidade com as diretrizes de integridade científica e boas práticas acadêmicas recomendadas pela CAPES, os

autores declaram que utilizaram ferramentas de inteligência artificial, incluindo *Gemini flash 3.8*, exclusivamente para auxiliar na melhoria da linguagem e legibilidade deste manuscrito. O uso dessas ferramentas foi realizado sob supervisão humana, e os autores revisaram e editaram cuidadosamente o conteúdo, assumindo total responsabilidade pelo texto final publicado.

REFERENCES

- [1] P. C. Hallal, L. B. Andersen, F. C. Bull, R. Guthold, W. Haskell, U. Ekelund *et al.*, “Global physical activity levels: surveillance progress, pitfalls, and prospects,” *The Lancet*, vol. 380, no. 9838, pp. 247–257, 2012.
- [2] G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals and Systems*, vol. 2, no. 4, pp. 303–314, 1989.
- [3] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, pp. 533–536, 1986.
- [4] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [5] W. S. McCulloch and W. Pitts, “A logical calculus of the ideas immanent in nervous activity,” *The Bulletin of Mathematical Biophysics*, vol. 5, pp. 115–133, 1943.
- [6] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [7] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” *Advances in Neural Information Processing Systems*, vol. 30, pp. 4766–4775, 2017.